

DeepSeek-R1 論文解析：強化學習如何提升 AI 推理能力？



Youngmi huang · Follow

9 min read · Jan 28, 2025



89



4



TL;DR

DeepSeek-R1 簡介

DeepSeek-R1 是一個偏重推理能力的大型語言模型，透過大規模強化學習（RL）提升推理能力。R1-Zero 純粹依賴 RL 訓練，展現強大推理能力，但存在無限重複、可讀性差等問題；R1 則引入冷啟動資料（Cold-Start Data）進行監督微調（SFT），在數學、程式碼與推理任務上的表現與 OpenAI-o1 相當。此外，DeepSeek 開源了 R1-Zero、R1 及多個蒸餾模型（如 Qwen 和 Llama），其中 R1-Distill-Qwen-32B 甚至超越 OpenAI-o1-mini，展現了蒸餾 R1 知識至開源模型的強大潛力。

1. 訓練方法：

DeepSeek-R1 採用多階段訓練流程，結合了監督微調（Supervised Fine-Tuning, SFT）和強化學習（Reinforcement Learning, RL）技術。特別地，模型在初始階段進行冷啟動微調，隨後進行推理導向的強化學習，最後再進行一次監督微調和強化學習。這種訓練策略旨在逐步提升模型的推理能力和生成質量。

2. 群體相對策略優化（GRPO）：

為了增強模型的推理能力，DeepSeek-R1 引入了 GRPO 方法（Group Relative Policy Optimization）。該方法不依賴於評論器網絡（critic），而是通過組內樣本的相對表現來優化策略。這種無評論器的設計簡化計算，並通過相對獎勵機制，引導模型生成更高質量的推理結果。

3. 開源與蒸餾貢獻：

DeepSeek-R1 的開源為社群提供了高品質的推理資料集，這些資料可用於蒸餾較小的模型，如 Qwen 和 Llama3 系列。經過蒸餾後的模型在多項基準測試中表現優異，顯示了高品質資料集對於提升模型性能的重要性。

• • •

大綱

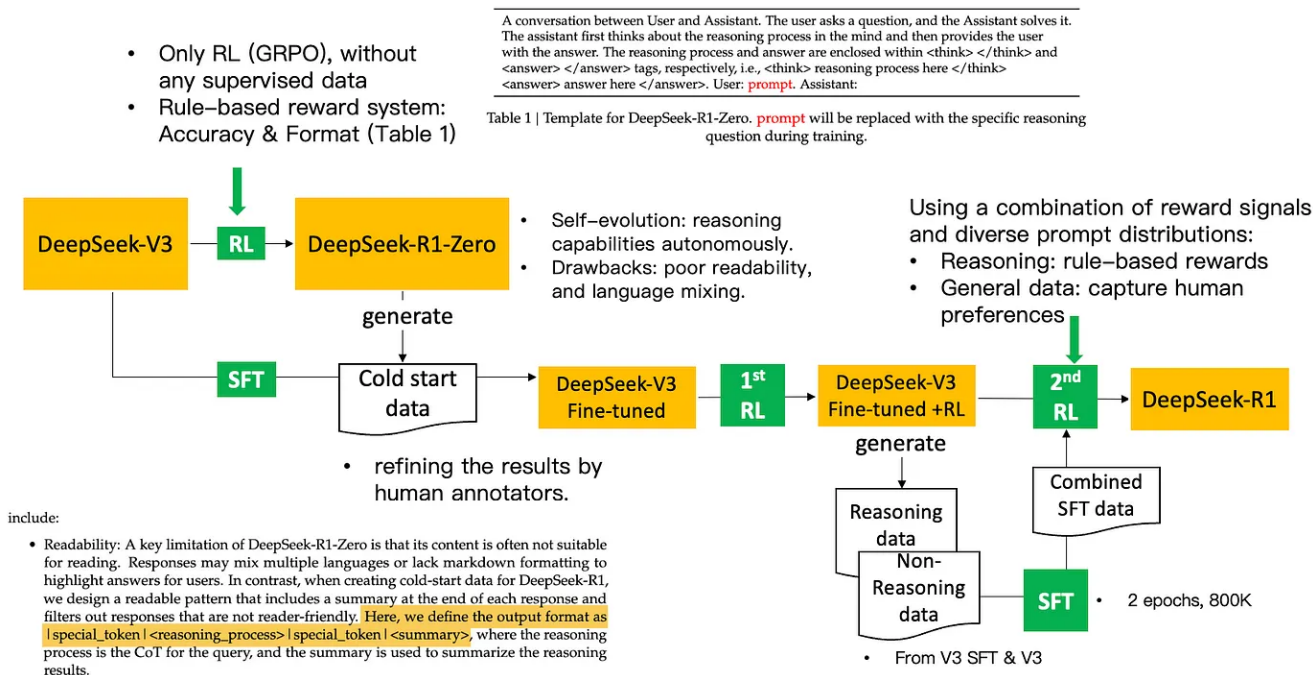
- ▶ DeepSeek-R1 的推理能力為何大幅躍進
- ▶ R1 的兩階段 RL 訓練：餵進的數據集有何不同
- ▶ DeepSeek-R1 vs. V3：全方位比較
- ▶ 實驗結果分析 – DeepSeek-R1 的模型表現
- ▶ R1 蒸餾模型對開源的貢獻是什麼？
- ▶ 實驗結果分析 – R1 蒸餾模型的表現
- ▶ 結論 & 後續應用觀察

DeepSeek-R1 的推理能力為何大幅躍進

- 推理能力的初獲得：在訓練 DeepSeek-R1-Zero 時，發現直接上 RL，雖然可以學習到驚人的推理能力，但是：產生的結果會有輸出語言不一致 + 可讀性差的問題（e.g. 開源社群有 qwen-distill-32B 的模型會有出現輸出 token 重複為 <think><think><think>的情形：[issue link](#)）

輸出更符合人類的偏好，需要 SFT 的步驟：將 DeepSeek-R1-Zero 的輸出經過人為整理成下述的格式後 (special_token|<reasoning_process>|special_token|<summary>)，從 DeepSeek-V3 進行 Fine-Tune，目的是先推理過程、再完成任務輸出總結，透過人類老師的校準後，獲得高質量的資料集。

兩階段 RL：第一階段的 RL 主要聚焦於推理能力的提升，尤其是數學與程式邏輯問題，同時優化輸出語言的一致性，這也是經過 Fine-Tune 後的 DeepSeek-V3 在此階段的核心訓練目標。第二階段 RL 則在前一階段強化推理能力的基礎上，進一步結合人類偏好，透過綜合獎勵機制優化模型的整體表現。



從 DeepSeek-R1 論文整理的訓練流程

GRPO 是什麼？

GRPO（Group Relative Policy Optimization，群體相對策略優化）是一種 RL 方法，專為提升 AI 推理能力而設計，並且比傳統方法更節省計算資源。

相較於經典的 PPO（Proximal Policy Optimization），GRPO 省略了 評論器（Critic），直接透過「組內比較獎勵」來優化 AI 的學習效果，特別適合數學、程式碼等需要邏輯推理的任務。GRPO 透過比較 AI 產生的多個解答，給表現較好的答案更高獎勵，讓 AI 自動學會選擇最優輸出，不再依賴固定標準評分。

為什麼 GRPO 拋棄了 Critic ？

傳統強化學習中的 Critic 負責評估動作的好壞，但這帶來了兩個問題：高計算成本和評估不穩定。GRPO 透過組內獎勵比較來取代 Critic，不僅降低計算需求，還能讓訓練更穩定。Critic 需要額外的參數與計算資源，而其評估錯誤時，可能導致 AI 學到錯誤策略，影響模型的收斂效果。相較之下，GRPO 直接使用組內樣本的相對優勢來更新策略，不僅讓學習更直觀，也避免了 Critic 可能帶來的錯誤評估，確保 AI 逐步向最優解靠攏。這種方法特別適用於數學推理、程式碼生成等可透過明確規則評估答案優劣的場景，讓訓練更高效、穩定。

R1 的兩階段 RL 訓練：餵進的數據集有何不同

Comparison of Input Data Coverage and Diversity

Specialities	Cold Start (2.3.1)	Rejection Sampling and SFT (2.3.3)
Data Size	high quality, with small size(~K)	high quality (~60K + ~20K)
Source	Human annotation	Reinforcement learning generated samples + original SFT data
Task	Focused on complex reasoning tasks	Reasoning tasks + general tasks
Scope	Mathematics, logic, long-chain reasoning	Includes writing, translation, Q&A, and broader scenarios
Diversity	Limited coverage	Significant increase in data diversity
Target	Improve initial reasoning ability	Optimize overall performance while maintaining strong reasoning capabilities

從 DeepSeek-R1 論文整理出的兩階段 RL 輸入的資料差異

DeepSeek-R1 vs. V3：全方位比較

特性	DeepSeek-V3	DeepSeek-R1
模型大小	總參數量 6710 億 (671B)，MoE 架構，每個 token 激活 370 億參數	總參數量與 V3 相當，基於 DeepSeek-V3-Base，採用類似的 MoE 架構
訓練方法	包含預訓練、監督微調 (SFT) 和強化學習 (RL)，使用 14.8 兆高品質文本進行預訓練	引入多階段訓練流程，冷啟動微調後進行推理導向的 RL 訓練，最後進行 SFT 和再次 RL 訓練
性能表現	在多項基準測試 (MMLU-Pro、GPQA-Diamond、MATH 500) 中達到或超越其他開源模型	在推理任務上性能卓越，與 OpenAI-o1-1217 表現相當，特別在數學、代碼和推理任務中表現優異
應用場景	適用於廣泛的 NLP 任務，如文本生成、閱讀理解、機器翻譯	專注於深度推理任務，如數學問題求解、代碼生成和複雜問題的分析
創新點	採用 MoE 架構提升效率，結合大規模數據的預訓練和多階段優化流程	引入 GRPO 方法進行 RL 訓練，改進推理能力，特別設計針對未微調模型的性能提升

實驗結果分析 — DeepSeek-R1 的模型表現

在表格中，有些基準測試 (benchmark) 並未提供 OpenAI-o1 的分數，但從有提供的項目來看，**DeepSeek-R1** 在與 OpenAI-o1 的對比中，共 **11** 個項目中有 **4** 項超越了 **O1**，尤其在 **Code** 和 **Math** 領域，兩者的表現非常接近。

3.1. DeepSeek-R1 Evaluation

Benchmark (Metric)		Claude-3.5- Sonnet-1022	GPT-4o 0513	DeepSeek V3	OpenAI o1-mini	OpenAI o1-1217	DeepSeek R1
Architecture		-	-	MoE	-	-	MoE
# Activated Params		-	-	37B	-	-	37B
# Total Params		-	-	671B	-	-	671B
English	MMLU (Pass@1)	88.3	87.2	88.5	85.2	91.8	90.8
	MMLU-Redux (EM)	88.9	88.0	89.1	86.7	-	92.9
	MMLU-Pro (EM)	78.0	72.6	75.9	80.3	-	84.0
	DROP (3-shot F1)	88.3	83.7	91.6	83.9	90.2	92.2
	IF-Eval (Prompt Strict)	86.5	84.3	86.1	84.8	-	83.3
	GPQA Diamond (Pass@1)	65.0	49.9	59.1	60.0	75.7	71.5
	SimpleQA (Correct)	28.4	38.2	24.9	7.0	47.0	30.1
	FRAMES (Acc.)	72.5	80.5	73.3	76.9	-	82.5
	AlpacaEval2.0 (LC-winrate)	52.0	51.1	70.0	57.8	-	87.6
	ArenaHard (GPT-4-1106)	85.2	80.4	85.5	92.0	-	92.3
Code	LiveCodeBench (Pass@1-COT)	38.9	32.9	36.2	53.8	63.4	65.9
	Codeforces (Percentile)	20.3	23.6	58.7	93.4	96.6	96.3
	Codeforces (Rating)	717	759	1134	1820	2061	2029
	SWE Verified (Resolved)	50.8	38.8	42.0	41.6	48.9	49.2
	Aider-Polyglot (Acc.)	45.3	16.0	49.6	32.9	61.7	53.3
Math	AIME 2024 (Pass@1)	16.0	9.3	39.2	63.6	79.2	79.8
	MATH-500 (Pass@1)	78.3	74.6	90.2	90.0	96.4	97.3
	CNMO 2024 (Pass@1)	13.1	10.8	43.2	67.6	-	78.8
Chinese	CLUEWSC (EM)	85.4	87.9	90.9	89.9	-	92.8
	C-Eval (EM)	76.7	76.0	86.5	68.9	-	91.8
	C-SimpleQA (Correct)	55.4	58.7	68.0	40.3	-	63.7

Table 4 | Comparison between DeepSeek-R1 and other representative models.

R1 的蒸餾模型對開源的貢獻是什麼？

DeepSeek-R1 的一大貢獻在於，它透過用於訓練 R1 的高質量資料集，進一步 **fine-tune** 了開源的大型語言模型，如 **Qwen**（阿里巴巴）和 **Llama**（Meta）。

這對開源社群的貢獻在於：

- 1. 高效模型訓練策略：提供了一種通過高品質資料與合理訓練方法，讓較小模型達到甚至超越大型模型的方法，降低算力需求，提高可及性。

推理能力的普及化：使開源模型也能獲得強大的推理能力，推動 AI 在數學、程式設計等領域的應用發展。

促進開源創新：社群可以基於這些高效的蒸餾技術與資料集，進一步改進並發展出更多適用於不同場景的 LLM 模型，例如 multi-modal

LLM。

2.4. Distillation: Empower Small Models with Reasoning Capability

To equip more efficient smaller models with reasoning capabilities like DeepSeek-R1, we directly fine-tuned open-source models like Qwen (Qwen, 2024b) and Llama (AI@Meta, 2024) using the 800k samples curated with DeepSeek-R1, as detailed in §2.3.3. Our findings indicate that this straightforward distillation method significantly enhances the reasoning abilities of smaller models. The base models we use here are Qwen2.5-Math-1.5B, Qwen2.5-Math-7B, Qwen2.5-14B, Qwen2.5-32B, Llama-3.1-8B, and Llama-3.3-70B-Instruct. We select Llama-3.3 because its reasoning capability is slightly better than that of Llama-3.1.

For distilled models, we apply only SFT and do not include an RL stage, even though incorporating RL could substantially boost model performance. Our primary goal here is to demonstrate the effectiveness of the distillation technique, leaving the exploration of the RL stage to the broader research community.

這些創新不僅提升了模型的推理能力，還為開源社群提供了寶貴的資源，促進了人工智慧領域的進一步發展。

實驗結果分析 — R1 蒸餾模型的表現

DeepSeek-R1-Distill-Qwen-7B: 分別對應至來源 — 技術 — 規模。老師模型來源是 DeepSeek-R1，將老師的知識蒸餾至阿里的 Qwen 模型中，模型參數量是 7B ([Huggingface Link : Qwen-7B](#))。

以 AIME2024 (American Invitational Mathematics Examination) 舉例，這是美國高中數學比賽的問題，主要評估數學推理和邏輯能力。

1. DeepSeek-R1-Distill-Qwen-7B vs QwQ-32B-Preview (黃色): 蒸餾後的 **Qwen-7B** 只需 **7B** 參數，就能超越 **32B** 原始模型 (**QwQ-32B-Preview**)，使較小模型擁有更強的推理能力。

DeepSeek-R1-Distill-Qwen-32B vs OpenAI-o1-mini (綠色): 在與 OpenAI in-house 模型 O1-mini 的對比，**Qwen-32B** (經 **R1** 蒸餾) 在多項基準測試中達到或超越 O1-mini，表明經過蒸餾後的 **Qwen 32B** 具備匹敵 OpenAI 模型的能力。

3.2. Distilled Model Evaluation

Model	AIME 2024		MATH-500	GPQA Diamond	LiveCode Bench	CodeForces
	pass@1	cons@64	pass@1	pass@1	pass@1	rating
GPT-4o-0513	9.3	13.4	74.6	49.9	32.9	759
Claude-3.5-Sonnet-1022	16.0	26.7	78.3	65.0	38.9	717
OpenAI-o1-mini	63.6	80.0	90.0	60.0	53.8	1820
QwQ-32B-Preview	50.0	60.0	90.6	54.5	41.9	1316
DeepSeek-R1-Distill-Qwen-1.5B	28.9	52.7	83.9	33.8	16.9	954
DeepSeek-R1-Distill-Qwen-7B	55.5	83.3	92.8	49.1	37.6	1189
DeepSeek-R1-Distill-Qwen-14B	69.7	80.0	93.9	59.1	53.1	1481
DeepSeek-R1-Distill-Qwen-32B	72.6	83.3	94.3	62.1	57.2	1691
DeepSeek-R1-Distill-Llama-8B	50.4	80.0	89.1	49.0	39.6	1205
DeepSeek-R1-Distill-Llama-70B	70.0	86.7	94.5	65.2	57.5	1633

Table 5 | Comparison of DeepSeek-R1 distilled models and other comparable models on reasoning-related benchmarks.

3.意義

- R1 產出的資料集質量極高，而蒸餾的效果主要取決於 fine-tune data 的品質。因此，當 Qwen 和 Llama3 透過高品質的資料集進行微調後，它們的 benchmark 分數顯著提升，甚至超越原始未蒸餾的大模型。

證明資料品質的影響力：不是參數越大，性能就一定越好；高品質資料集能讓較小的模型達到更高效的推理能力。

驗證蒸餾技術的有效性：如果蒸餾後的 7B 參數模型能在推理、數學、邏輯等測試中擊敗 14B 模型，說明蒸餾過程成功轉移了知識，提升了模型性能與效率。

. . .

結論 & 後續應用觀察

- 1.關於監管問題：社群上有看到敏感詞不回答，但其實是應用端的禁止。試了好幾次不同的 Prompt（寫小說, 羅馬數字轉換 etc），發現模型可以正常輸出推理過程，但是模型輸出到關鍵詞時的瞬間會觸發應用層的審查機制，馬上變成無法回答。

- 可以繞過的 prompt: <https://composio.dev/blog/notes-on-the-new-deepseek-r1/>

本地 70B 可以獲得完整答案（不走 application layer）：

<https://huggingface.co/deepseek-ai/DeepSeek-R1/discussions/42>

2.對於應用：關於數學題目、程式碼問題等，可以考慮交給 DeepSeek-R1 執行，身為每月 20 USD 的 OpenAI 用戶，在 DeepSeek-R1 還沒出來前，都要兢兢業業地使用一週 50 次的 quota。

在 AI 共處的時代，人類的生存與價值證明已經很辛苦了，沒想到連思考過程的邏輯漏洞都還可以被 AI 們搶著幫忙。不過還是很開心可以和風起雲湧的大模型們學習與應用在工作+生活。


歡迎提供想法。

參考資料

- [DeepSeek-R1 Paper](#)

[*A fully open reproduction of DeepSeek-R1*](#)：設法實現 DeepSeek-R1 的項目

[訓練流程詳細版](#)



Deepseek

Llm