

【論文解讀】DeepSeek-V3技術報告



tomsheep



北京字跳網路技術有限公司 從業人員

+關注他

287 人讀同了該文章

收起

TL;DR

DeepSeek團隊2024年12月末發佈了V3版本，個人認為開源模型的標竿基本就看Llama、Qwen+、DeepSeek這幾家了，小模型可以加上Gemma+和Phi。

主要思路：

降低訓練成本：通過FP8低精度訓練、DualPipe+雙向流水線等

降低推理成本：最佳化MoE**負載平衡+**等

最佳化訓練資料：使用 14.8T 高品質、多樣化的 token，增加了數學和程式設計樣本的比例，擴大了多語言覆蓋範圍

進一步提升效果：多 Token 預測（MTP+）、從 DeepSeek-R1 中蒸餾推理能力等

效果：

在 MMLU、MMLU-Pro、GPQA+ 等知識性基準測試中，性能與 GPT-4o、Claude-3.5-Sonnet+ 等領先閉源模型相當。

在 程式碼和數學 基準測試中，取得了最先進的性能，甚至超越了 GPT-4o。

在 AlpacaEval 2.0 和 Arena-Hard 的開放式評估中表現出色。

訓練成本：

總成本：278.8 萬 H800 GPU 小時，約 557.6 萬美元。

預訓練效率：每訓練 1 萬億個 token 僅需 18 萬 H800 GPU 小時，訓練過程穩定，無需回滾。

開源：

技術報告：[DeepSeek-V3 Technical Report](#)

權重（大小足有671B，FP8精度）：[deepseek-ai/DeepSeek-V3-Base · Hugging Face](#)

主要內容

1. 作者和團隊資訊

作者/團隊：DeepSeek-AI+ 團隊一直走在開源模型發展的前列，此前發佈的 DeepSeek 系列模型一直在Math即Coding能力上為人稱道。

2. 背景和動機

發表時間：2024年12月末。

研究問題：如何在保證模型性能的同時，降低訓練成本，並進一步提高開源語言模型+的能力？

問題背景：近年來，大型語言模型（LLMs）+發展迅速，但訓練和部署成本仍然很高。同時，開源模型在性能上與閉源模型還存在一定的差距。為瞭解決這些問題，DeepSeek-AI 團隊提出了 DeepSeek-V3，旨在實現高性能、低成本的開源 LLM+。

補充說明：

MoE (Mixture-of-Experts):混合專家模型+，是一種利用多個小型專家模型共同完成任務的架構。每個專家模型只處理部分輸入，從而提高模型的效率和擴展性。

3. 相關研究

▲贊同 287 ▼

●26 條評論

🔗分享

♥喜歡

★收藏

📄申請轉載

...

已有的開源模型： DeepSeek 團隊提到了 DeepSeek 系列、LLaMA 系列、Qwen 系列和 Mistral 系列等開源模型，這些模型都在努力追趕開源模型。

已有的 MoE 模型+： GShard 是一個傳統的 MoE 模型，而 DeepSeekMoE+ 使用了更細粒度的專家，並隔離了一些專家作為共享專家。

已有的低精度訓練方法： 論文提到了 FP8 **混合精度訓練+**，這是一種利用低精度資料格式進行訓練的方法，可以加速訓練並減少記憶體使用。

現有方法的不足：

MoE 的負載平衡問題： 傳統的 MoE 模型通常依賴於**輔助損失函數+**來平衡專家負載，但過大的輔助損失會損害模型性能。

低精度訓練+的挑戰： 低精度訓練容易受到異常值的影響，而且在大型語言模型的預訓練中應用仍然存在挑戰。

4. 核心思路

整體思路： 在 DeepSeek-V2 的基礎上，通過引入新的架構和訓練策略，進一步提升模型的性能，同時降低訓練成本。

核心創新點：

無輔助損失的負載平衡策略： 通過引入偏置項動態調整專家負載，避免了傳統輔助損失帶來的性能損失。

多 Token 預測 (MTP)： 在每個位置預測多個未來的 token，增加訓練訊號，提高模型的資料效率。

FP8 混合精度訓練框架： 首次驗證了 FP8 訓練在超大規模模型上的可行性和有效性。

高效的訓練框架： 通過 **DualPipe 演算法+**和最佳化的通訊核心，實現了近乎零開銷的跨節點通訊。

從 DeepSeek-R1 中提煉推理能力： 將 DeepSeek-R1 的推理模式融入 DeepSeek-V3，提高了模型的推理性能。

靈感來源：

無輔助損失負載平衡: 該策略受到了 [Wang et al.\(2024a\)](#) 的研究啟發，旨在最小化負載平衡對模型性能的負面影響。

多Token預測: 該策略受到了 [Gloeckle et al.\(2024\)](#) 的啟發，旨在通過更密集的訓練訊號提高模型性能。

FP8 混合精度訓練: 該策略受到了 [Dettmers et al.\(2022\)](#) 等一系列低精度訓練研究的啟發，旨在加速訓練並降低記憶體佔用。

5. 方案與技術

基礎架構：

MLA (Multi-Head Latent Attention)： 多頭潛在**注意力機制+**，通過**低秩壓縮+**減少 **KV 快取+**，提高推理效率。

DeepSeekMoE： 一種高效的混合專家模型架構，使用更細粒度的專家，並隔離部分專家作為共享專家。




Figure 2 | Illustration of the basic architecture of DeepSeek-V3. Following DeepSeek-V2, we adopt MLA and DeepSeekMoE for efficient inference and economical training.

負載平衡：

無輔助損失負載平衡： 為每個專家引入一個偏置項，在路由時使用，但計算門控值時仍然使用原始的親和性得分。訓練過程中，動態調整偏置項，使得專家負載平衡。

序列級輔助損失（補充）： 為了防止在單個序列中出現極端的失衡，使用一個非常小的輔助損失來確保序列內的負載平衡。

多 Token 預測 (MTP)：

MTP 模組： 使用 D 個序列模組，每個模組包含一個共享的**嵌入層**、一個共享的輸出頭、一個 **Transformer 塊**和一個投影矩陣。

MTP 目標： 計算每個預測深度的交叉熵損失，並乘以一個**權重因子**，作為額外的訓練目標。




Figure 3 | Illustration of our Multi-Token Prediction (MTP) implementation. We keep the complete causal chain for the prediction of each token at each depth.

訓練框架：

DualPipe 演算法： 一種高效的流水線平行演算法，通過重疊前向和後向計算與通訊來減少流水線氣泡。

高效的跨節點通訊核心： 利用 **IB** 和 **NVLink** 頻寬，減少通訊開銷。

FP8 訓練

混合精度框架： 大部分計算操作在 FP8 精度下進行，而一些關鍵操作保持原始精度（BF16 或 FP32+）。

細粒度量化： 對啟動值和權重進行分組縮放，以適應異常值，提高量化精度。

增加累積精度： 使用 **CUDA** 核心進行高精度累積，以解決 FP8 GEMM 中的下溢問題。

線上量化： 線上計算最大絕對值用於縮放，並直接將啟動或權重量化為 FP8 格式。

低精度儲存和通訊： 使用低精度格式（FP8 或 BF16）來儲存和傳遞啟動值、梯度等，以降低記憶體和通訊開銷。

長文字擴展


YaRN: 使用 YaRN 技術對模型的上下文長度進行擴展，逐步從 4K 擴展到 32K，再到 128K。

推理和部署：

預填充階段： 使用 4 路張量+平行、序列平行和 8 路資料平行，並使用冗餘專家來平衡負載。

解碼階段： 使用 4 路張量平行、序列平行和 80 路資料平行，並通過點對點 IB 傳輸進行通訊。

6. 實驗與結論



預訓練：

資料： 使用 14.8T 高品質和多樣化的 token 進行預訓練，資料中數學和程式設計樣本的比例更高，並擴大了多語言覆蓋範圍。

穩定性： 預訓練過程非常穩定，沒有出現不可恢復的損失峰值或回滾。

Context Length Extension: 使用兩階段上下文長度擴展，先擴展到 32K，再擴展到 128K。

後訓練：

有監督微調 (SFT)： 使用 150 萬個跨多個領域的指令微調資料集進行微調。

強化學習 (RL)： 使用基於規則的獎勵模型和基於模型的獎勵模型，結合 GRPO 演算法進行強化學習，並從 DeepSeek-R1 中提煉推理能力。

評估：

標準評測： DeepSeek-V3 在 MMLU、MMLU-Pro、GPQA 等知識性基準測試中表現出色，與 GPT-4o 和 Claude-3.5-Sonnet 等領先的閉源模型相當。在程式碼和數學基準測試中，DeepSeek-V3 也取得了最先進的性能。

開放式評估： 在 AlpacaEval 2.0 和 Arena-Hard 的開放式評估中，DeepSeek-V3 也展示了優異的表現。

多 token 預測的加速效果： 通過 MTP 技術，DeepSeek-V3 的解碼速度提高了 1.8 倍。

訓練成本：

總成本： DeepSeek-V3 的完整訓練（包括預訓練、上下文擴展和後訓練）僅需 278.8 萬 H800 GPU 小時，總成本約 557.6 萬美元。

預訓練成本： 預訓練階段每訓練 1 萬億個 token 僅需 18 萬 H800 GPU 小時。

訓練穩定性: 整個訓練過程中沒有發生任何不可恢復的損失峰值或回滾。

核心結論： DeepSeek-V3 是一款高性能、低成本的開源模型，其性能與領先的閉源模型相當，並在多個基準測試中取得了最先進的結果，尤其是在程式碼和數學方面。

7. 貢獻

架構創新：

提出了無輔助損失的負載平衡策略，避免了因追求負載平衡而導致的性能下降。

驗證了多 token 預測目標對模型性能的提升效果，並可用於推理解碼加速。

預訓練：

設計了 FP8 混合精度訓練框架，首次驗證了 FP8 訓練在超大規模模型上的有效性。

通過演算法、框架和硬體的協同設計，解決了跨節點 MoE 訓練中的通訊瓶頸，實現了近乎完全的計算-通訊重疊。

以較低的成本（266.4 萬 H800 GPU 小時）完成了 DeepSeek-V3 的預訓練，產生了目前最強的開源基礎模型。

後訓練：

提出了一種創新的方法，從 DeepSeek-R1 系列模型中提煉推理能力，並將其應用於 DeepSeek-V3。

核心評估結果：

知識：在 MMLU、MMLU-Pro 和 GPQA 等基準測試中，DeepSeek-V3 超過了所有其他開源模型。

程式碼、數學和推理：DeepSeek-V3 在數學相關基準測試中達到了最先進的性能，甚至在某些基準測試中超過了 GPT-4o。在程式碼相關任務中，DeepSeek-V3 是編碼競賽基準測試中表現最佳的模型。

對後續研究的啟發和影響：

開源社區+：DeepSeek-V3 作為一款高性能的開源模型，將推動開源社區的發展，為研究人員和開發者提供有力的工具。

低成本訓練：論文展示的 FP8 訓練和高效訓練框架，為後續研究如何降低大型模型訓練成本提供了參考。

MoE架構：論文對 MoE 架構的最佳化，為如何提高 MoE 模型的性能和效率提供了新的思路。

推理加速：MTP 和推測解碼等技術，為如何提升 LLM 推理速度提供了可行方案。

8. 不足

部署方面的挑戰：

DeepSeek-V3 的推理對硬體要求高，需要較大的部署單元（4 個節點，32 個 GPU），這對於小型團隊來說可能是一個負擔。

雖然 DeepSeek-V3 的**推理速度+**比 DeepSeek-V2 快了兩倍以上，但仍有提升空間。

部分任務仍有差距：雖然 DeepSeek-V3 在多個方面表現出色，但在一些任務上，比如英語事實知識方面，仍然落後於 GPT-4o 和 Claude-3.5-Sonnet。

可能的未來方向：

更高效的模型架構：研究更高效的模型架構，進一步提高訓練和推理效率。

更豐富的訓練資料：探索更多的資料來源，提高訓練資料的質量和多樣性。

更強的推理能力：擴展推理長度和深度，增強模型的推理能力。

更多維度的模型評估：開發更全面的模型評估方法，避免過度最佳化固定基準測試。

QA

Q1：什麼是 MoE 模型？為什麼 DeepSeek-V3 要使用 MoE 架構？

MoE (Mixture-of-Experts) 模型，即混合專家模型，是一種將多個小型專家模型組合起來，共同完成任務的架構。每個專家模型只處理部分輸入，從而提高模型的效率和擴展性。

DeepSeek-V3 使用 MoE 架構的原因主要有以下幾點：

提高模型容量：MoE 可以顯著增加模型的參數數量，而無需像稠密模型那樣增加計算量。這使得模型可以學習更複雜的模式和關係，提高模型的性能。

降低訓練成本：雖然 MoE 模型的總參數量很大，但每次啟動的參數量卻很小，從而減少了訓練所需的計算資源。

提高推理效率：在推理時，只有部分專家被啟動，從而降低了推理的計算成本。

Q2：什麼是 Multi-Head Latent Attention (MLA)？它如何減少鍵值快取的大小？

Multi-Head Latent Attention (MLA)，即多頭潛在注意力機制，旨在減少推理階段的記憶體佔用。MLA 和傳統的 **MHA+** 的主要區別在於：

KV 快取：在傳統的 MHA 中，每個 token 的 Key 和 Value 向量都需要快取起來，這在長文字生成中會佔用大量的視訊記憶體。而 MLA 通過**低秩壓縮技術+**，將 Key 和 Value 向量壓縮成低維度的潛在向量，只需快取壓縮後的表示，從而顯著減少 KV 快取的記憶體佔用。

通俗類比：想像你在聽一場演講，傳統的注意力機制需要記住每個時間點的所有細節（就像記錄每一秒的錄音）。而 MLA 則只提取關鍵資訊（就像只記錄每個重點句子），這樣需要記憶的資訊就大大減少了。

公式上，鍵和值的計算方式為：

其中， x 是輸入表示， W_k 、 W_v 是**投影矩陣**， b_k 是旋轉位置編碼。

Q3：為什麼需要負載平衡？DeepSeek-V3 的無輔助損失負載平衡策略是什麼？

在 MoE 模型中，如果專家負載不均衡，會導致以下問題：

路由崩潰：某些專家可能會被過度使用，而其他專家則被閒置。

計算效率降低：過度使用的專家會成為性能瓶頸，而閒置的專家則浪費了計算資源。

傳統 MoE 模型為了實現專家間的負載平衡，通常引入輔助損失。但輔助損失會對模型的主要最佳化目標產生干擾，可能導致性能下降。為瞭解決這個問題，DeepSeek-V3 提出了無輔助損失的負載平衡策略。該策略的核心思想是：

引入偏置項：為每個專家引入一個偏置項，並將這個偏置項加入到親和度得分中，從而影響路由決策。

動態調整偏置項：在訓練過程中，如果一個專家被過度使用，則減小其偏置項；如果一個專家被閒置，則增大其偏置項。這樣，可以動態調整專家負載，使其達到均衡。

不使用輔助損失：偏置項只用於路由，而不影響最終的門控值計算，從而避免了傳統輔助損失對模型性能的損害。

類比：想像一下你在一個餐廳裡，有多個廚師。如果顧客都點同樣的菜，那麼只有一個廚師會很忙，而其他廚師則沒事做。為瞭解決這個問題，你可以告訴顧客：「今天點這道菜可以打折」，或者「點其他菜可以更快上菜」。這樣，就可以引導顧客點不同的菜，讓所有廚師都忙起來。

DeepSeek-V3 的無輔助損失負載平衡策略就類似於這個引導顧客點不同菜的策略。

Q4：什麼是 Multi-Token Prediction (MTP)？它為什麼能提高模型性能？

在傳統的語言模型訓練中，模型通常只預測下一個標記。MTP 則是在每個位置上，讓模型預測多個未來的標記。

實現方法：

引入了**多個預測模組**，每個模組負責預測不同深度（未來第幾個）的標記。

在訓練過程中，對每個深度的預測計算損失，然後將這些**損失平均**，作為整體的 MTP 損失。

好處：

增加訓練訊號：通過預測多個 token，模型可以獲得更密集的訓練訊號，提高資料效率。

增強預規劃能力：MTP 可以幫助模型更好地預先規劃未來 token 的表示，使其更好地捕捉長距離依賴關係，從而提高模型的性能。

Q5：什麼是 FP8 混合精度訓練？為什麼 DeepSeek-V3 要使用 FP8 訓練？

在深度學習訓練中，使用低精度浮點數（如 FP16、FP8）可以降低計算和儲存需求，提高訓練速度。但低精度可能導致數值不穩定和模型性能下降。

解決方案：

精細量化策略：

細粒度量化：對張量進行小塊劃分（如 1×128 或 128×128 ），對每個小塊單獨計算縮放因子，進行量化，減少了量化誤差帶來的影響。

提高積累精度：

增加加運算的精度：在進行**矩陣乘法+**累加時，將部分結果提升到更高精度（如 FP32）進行積累，減少了因低精度引入的誤差。

混合精度訓練框架：

保留關鍵操作的高精度：對於敏感的操作，如嵌入層、**歸一化層+**等，仍然使用高精度計算，確保訓練的穩定性。

DeepSeek-V3 使用 FP8 訓練的主要原因是：

加速訓練：FP8 格式可以加速 GEMM (General Matrix Multiplication) 等核心計算操作，從而提高訓練速度。

減少記憶體使用：FP8 格式可以顯著減少記憶體佔用，使得在有限的視訊記憶體中訓練更大的模型成為可能。

突破硬體限制:目前 **NVIDIA H100+** 及以上的 GPU 已經對 FP8 有了較好的支援，而 DeepSeek-V3 使用了 FP8 混合精度訓練，使其可以更好地利用硬體性能。

Q6：DeepSeek-V3 的 DualPipe 演算法是如何工作的？它如何解決通訊瓶頸？

DualPipe 演算法是 DeepSeek-V3 中用於解決通訊瓶頸的一種高效流水線平行演算法。它的核心思想是通過重疊前向和後向計算與通訊，從而減少流水線氣泡，提高訓練效率。

具體來說，DualPipe 演算法：

雙向流水線：同時從流水線的兩端輸入 **micro-batch+**，實現雙向平行計算。

計算-通訊重疊：將每個 chunk 分成多個部分，並調整 GPU SM 用於通訊和計算的比例，使得計算和通訊可以相互重疊。

減少流水線氣泡：通過雙向流水線和計算-通訊重疊，減少了流水線中的等待時間，從而提高了訓練效率。

類比：你可以將 DualPipe 演算法想像成一個生產線。傳統的流水線是按順序一個一個地處理產品，而 DualPipe 演算法是同時從兩個方向處理產品，並讓不同環節同時進行，從而提高了生產效率。

Q7：DeepSeek-V3 是如何進行**知識蒸餾+**的？它和傳統的知識蒸餾有什麼不同？

DeepSeek-V3 使用了一種特殊的知識蒸餾方法，從 DeepSeek-R1 模型中提煉推理能力。與傳統的知識蒸餾不同，DeepSeek-V3 的知識蒸餾：

重點在於推理模式：不是簡單地模仿 R1 的輸出，而是將 R1 的反思和驗證模式融入到 DeepSeek-V3 中。

生成多樣化的 SFT 資料：通過讓 R1 生成帶有反思和驗證的響應，為 DeepSeek-V3 提供更高品質的 SFT 資料。

在強化學習中運用：在 RL 階段，通過高溫度採樣生成融合了 R1 和原始資料的響應，使模型學習 R1 的推理模式。

Q8：論文中提到的 **tile-wise** 和 **block-wise** 量化是什麼意思？

tile-wise 和 **block-wise** 量化是用於提高 FP8 量化精度的兩種細粒度量化方法：

tile-wise 量化：對於啟動值 (activations)，將 $1 \times N_e$ 的元素分組成一個 tile，然後在 tile 內進行縮放 (scaling)。這裡的 N_e 通常是 128，所以就是一個 1×128 的 tile。這意味著，對於每一個 token，每 128 個通道 (channel) 會被分成一組。

block-wise 量化：對於權重 (weights)，將 $N_e \times N_e$ 的元素分組成一個 block，然後在 block 內進行縮放。這裡的 N_e 也通常是 128，所以就是一個 128×128 的 block。這意味著，每 128 個輸入通道和 128 個輸出通道會被分組成一個 block。

這種細粒度的量化方法可以更好地適應啟動值和權重中的異常值，提高量化的精度，從而使模型能夠更有效地利用低精度的 FP8 格式進行訓練。

類比：你可以將 **tile-wise** 和 **block-wise** 量化想像成在打包貨物時，不是把所有貨物都放在一個大箱子裡，而是將它們根據形狀、大小等進行分類，然後分別打包。這樣可以更好地利用空間，減少貨物之間的擠壓和碰撞。

Q9：DeepSeek-V3 與其他大型語言模型相比，有什麼優勢？

高效的訓練和推理：採用了 MLA 和 DeepSeekMoE 架構，減少了記憶體佔用和計算需求，實現了高效的訓練和推理。

優異的性能：在多個基準測試上，DeepSeek-V3 超越了一些其他開源模型，在數學、程式碼生成、知識問答等任務上表現出色，接近甚至超過了一些閉源模型。

低訓練成本：由於採用了 FP8 訓練和最佳化的訓練框架，DeepSeek-V3 的訓練成本顯著降低，總共只花費了 278.8 萬 H800 GPU 小時。

開源：DeepSeek-V3 是目前性能最強的開源模型之一，為研究者和開發者提供了寶貴的資源，促進了人工智慧社區的共同進步。

Q10：在推理階段，如何保證專家負載平衡和高效推理？

挑戰：在推理階段，專家負載可能不均衡，導致一些專家過載，影響推理效率和吞吐量。

解決方案：

冗餘專家部署：

- 檢測高負載專家：**通過線上統計，識別負載較高的專家。
- 冗餘部署：**對高負載的專家進行冗餘部署，增加其副本，均攤負載。

動態調整：

- 定期調整冗餘專家集：**根據即時負載情況，動態調整哪些專家需要冗餘部署。
- 專家重新排列：**在節點內部，根據專家的負載情況，重新排列專家的部署，提高 GPU 的利用率。

最佳化的通訊策略：

- 跨節點通訊最佳化：**通過高效的 All-to-All 通訊核心，降低通訊開銷。
- 計算與通訊重疊：**利用 DualPipe 演算法，將計算和通訊階段重疊，隱藏通訊延遲。

Q11：DeepSeek-V3 的訓練過程為什麼穩定，沒有出現不可恢復的損失尖峰？

架構最佳化：採用了改進的 DeepSeekMoE 架構和無輔助損失的負載平衡策略，避免了路由崩潰等問題，保證了訓練的穩定性。

精細的訓練策略：

- 學習率調度：**合理的學習率增長和衰減策略，避免了訓練過程中的不穩定性。
- 梯度裁剪：**設定梯度裁剪閾值，防止梯度爆炸。

混合精度訓練：通過 FP8 混合精度訓練，既提高了訓練效率，又避免了數值不穩定。

最佳化的訓練框架：DualPipe 等演算法減少了流水線中的氣泡，保持了訓練過程的連續性。

編輯於 2024-12-27 13:05 · IP 屬地北京

內容所屬專欄

硅基進化

AI技術的自學與教學

訂閱專欄

神經網路

訂閱專欄

電腦&通訊技術

關於技術的學習與總結。

訂閱專欄

deepseek LLM（大型語言模型） 人工智慧



理性發言，友善互動

26 條評論

默認 最新



伯樂
deepseek v3混合專家系統有多少個呢，我看AI生成有256個恐怖
01-04 · 廣東

回覆 2



劉智國
看了一下程式碼，deepseekV3有16B，236B和671B三種組態，針對671B，參數為：
"n_routed_experts": 256, "n_shared_experts": 1, "n_activated_experts": 8,
01-30 · 北京

● 回覆 ● 4



水dong方塊 · 劉智國
感謝, n_shared_experts (共享專家數量)
代表所有輸入都 共享 的專家數量。
這些專家會始終被使用，而不是通過路由選擇。
共享專家的作用通常是提供穩定的基線，以減少過度依賴動態路由。
示例：如果 n_shared_experts = 1，表示有 1 個專家總是被使用，不管路由如何選擇其他專家。
3 n_activated_experts (啟動專家數量)
代表每個輸入樣本最終 被選擇 多少個專家來處理。
01-31 · 美國

● 回覆 ● 2

展開其他 1 條回覆 >



Yuan
在MLA中，通過Low-Rank Matrix可以減少GPU儲存空間能理解，但是在基礎架構圖中右下角當recover完整KV矩陣喂給MHA的時候，還是需要從低秩矩陣中算出完整的KV矩陣，這不是還是需要原先N*N的矩陣GPU空間麼，似乎並沒有減少GPU HBM使用？我這裡沒有想明白。
01-29 · 上海

● 回覆 ● 1



tomsheep 作者
低秩矩陣可以看做是「常駐」視訊記憶體，而你說的還原出的N*N矩陣只是「臨時」佔用，用一下就可以釋放，所以「常駐」的這部分大大減少，宏觀的看就有了錯峰操作的空間
01-30 · 北京

● 回覆 ● 1



Today
AI生成的文章，驗證了嗎
01-31 · 上海

● 回覆 ● 喜歡



Mr Cat
“出了一種創新的方法，從 DeepSeek-R1 系列模型中提煉推理能力，並將其應用於 DeepSeek-V3。”這意思是V3也有與R1同樣強的推理能力。另外想瞭解下用於程式設計的話V3和R1哪個更強一點呢~
01-31 · 上海

● 回覆 ● 喜歡



tomsheep 作者
V3發佈在先，R1發佈在後，這篇文章中的R1並非完全體。V3雖然蒸餾了一部分推理能力，但單論推理能力肯定弱於R1。程式設計能力的話，也要看是哪種類型的程式設計，如果是普通的程式碼工程實現，V3即可，debug的話，有反思能力的R1更好
02-01 · 北京

● 回覆 ● 1



deft
個人認為Qwen的效果還是比較差的
01-28 · 北京

● 回覆 ● 喜歡



天高任鳥飛
我之前在關注Speculative decoding方向的時候，看過MTP提到的那一篇論文Better & Faster Large Language Models via Multi-token Prediction。當時的感覺是和Speculative decoding的另一篇論文Medusa基本是一樣的思路，然後當時好像認為那一篇論文的方法僅對一些問題有效，就是程式碼生成和理解方面的問題。然後deepseekv3中提到的改進的方法和可以說是Better與另一篇論文Eagle的思路的結合。那麼deepseekv3在其他方面的性能怎麼樣？
01-02 · 北京

● 回覆 ● 喜歡



tomsheep 作者
確實，看了下Eagle的論文，deepseekv3的MTP機制跟Eagle一樣，也維護了因果鏈，而不像原始的Better論文裡的各個頭是獨立的。不過deepseekv3把MTP用在了增強訓練訊號上，而不只是推理加速，我想這可能是性能提升的一個點。從論文給的實驗資料看，一些通用的benchmark比如MMLU、BBH都不錯
01-02 · 北京

● 回覆 ● 喜歡



IT果果日記
學習了
2024-12-31 · 湖北

● 回覆 ● 喜歡



牧之張
一眼GPT

...

2024-12-27 · 上海

● 回覆 ❤ 喜歡



tomsheep 作者

...

這個系列的論文解讀文章都是使用AI進行QA問答生成的，我個人覺得大幅提升了自己的資訊處理效率，也推薦嘗試

2024-12-27 · 北京

● 回覆 ❤ 8



順勢而為

...

測試了一下跟GPT一樣的邏輯，找不到GPT的答案後就會模稜兩可，甚至胡言亂語

01-28 · 廣東

● 回覆 ❤ 喜歡

[查看全部 12 條回覆](#) >



理性發言，友善互動