

别再只知道 Ollama 了，独家公开，DeepSeek R1 & Janus-Pro 本地部署高级版教程

原创 AI大模型-大飞 于 2025-02-05 09:44:37 发布 阅读量452 收藏 12 点赞数 10 版权

文章标签： 人工智能 大模型 AI大模型 大模型教程 DeepSeek 大模型学习 大模型部署



最近 DeepSeek 实在是太火了，总结了高赞的帖子以及现有的方式，基本符合下面两种模式。

- 1、Ollama、LM studio 这种一键安装 gguf 格式模型的软件，差不多可以实现 2 分钟完成本地部署
- 2、Chatbox 、CherryStudio、AnythingLLM 这种客户端软件，配合 ollama 可以进行可视化使用，并且添加 RAG 等功能。


今天给大家介绍下如何通过下载模型权重进行部署，包括 DeepSeek-R1 以及最新的 Janus-Pro 都可以按这个方式来部署。由于我们采用 transformers 下载了模型权重的方式部署，理论上所有模型都会支持，属于比较通用的方法，这个方法的缺点就是没有额外的加速推理的功能，推理速度会低于 Vllm、SGLang 等推理框架。

掌握了这个方法，你就又比别人更进一步。

一、模型下载

我们推荐国内用户使用 modelscope 去下载相关模型权重，下载速度更快、更稳定。ms 地址：
<https://www.modelscope.cn/organization/deepseek-ai>

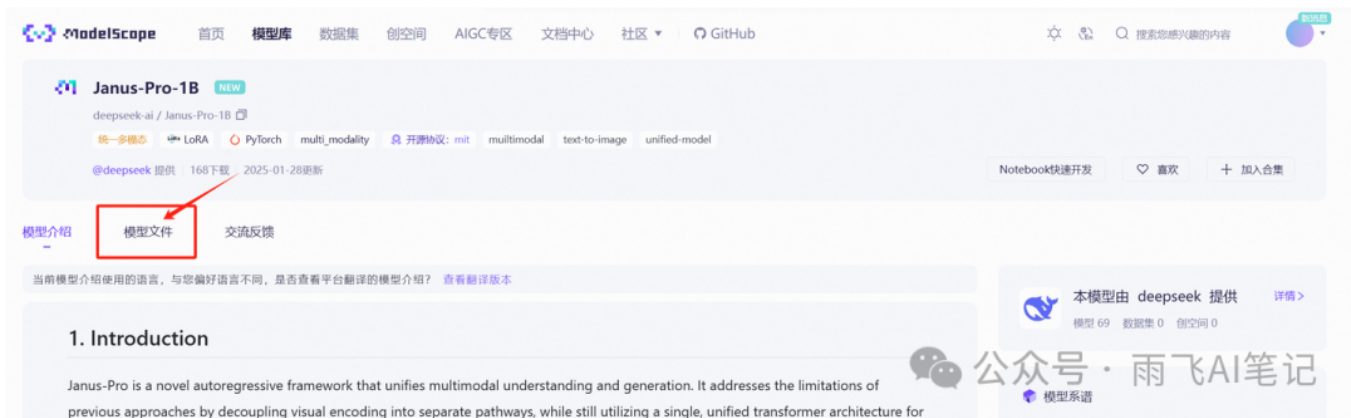
点击这个网址，就能看到 DeepSeek 的页面，红框里的模型就是我们熟悉的 R1 以及 Janus-Pro 模型，两者的下载过程是一样的，这里雨飞就以 Janus-Pro 为例，给大家演示下具体下载过程。




点击下方网址或者从红框内容进入，找到 Janus-Pro-1B 模型，打开如下方所示的页面，点击如图所示的「模型文件」按钮。

网址：<https://www.modelscope.cn/models/deepseek-ai/Janus-Pro-1B>

注意: Janus 是多模态的模型，1B 大小的模型显存占用在 8GB。如果低于 8GB 的，考虑用云服务器，或者去部署 DeepSeek R1 模型。



点击「下载模型」会弹出一个对话框。



我们推荐使用 Git 进行下载，这种方式更稳定，也比较常用。Git lfs 是用于下载大型文件必备的软件，可以根据下面所示的安装教程去进行安装：<https://git-lfs.com/>


```
1 | git lfs install` `git clone https://www.modelscope.cn/deepseek-ai/Janus-Pro-1B.git
```

执行上面命令，会在本地生成一个文件夹，等待下载模型完成。

二、环境配置


首先，需要下载 Janus 的项目，网址：<https://github.com/deepseek-ai/Janus>

点击右上角的 Code 按钮，在弹出的对话框中点击「Download ZIP」，将项目下载到本地，然后解压缩到一个目录。



然后可以在 VS code 或者 Cursor 中打开此项目，正常需要显示下面这些内容，则表示没有任何问题。





接下来需要安装 Python 环境以及安装相关依赖，有不清楚的地方可以去问问 AI 具体哪一步出现了问题。打开命令行，在当前目录下执行下方命令等待安装完成，如果遇到了网络问题可以换成下面第二个命令。

```
1 | pip install -e .
```

命令2:使用清华源安装

```
1 | pip install -r requirements.txt -i https://pypi.tuna.tsinghua.edu.cn/simple
```

三、实战

在上面打开的项目页面向下滑动，看到第三部分「Quick Start」，我们可以使用这里的示例进行验证。官方提供了两个案例，一个是多模态的图片理解，另外一个文生图。

3. Quick Start

▼ Janus-Pro

Installation

On the basis of `Python >= 3.8` environment, install the necessary dependencies by running the following command:

```
pip install -e .
```

Simple Inference Example

Multimodal Understanding

```
import torch
from transformers import AutoModelForCausalLM
from janus.models import MultiModalityCausalLM, VLChatProcessor
from janus.utils.io import load_pil_images

# specify the path to the model
model_path = "deepseek-ai/Janus-Pro-7B"
vl_chat_processor: VLChatProcessor = VLChatProcessor.from_pretrained(model_path)
tokenizer = vl_chat_processor.tokenizer

vl_gpt: MultiModalityCausalLM = AutoModelForCausalLM.from_pretrained(
    model_path, trust_remote_code=True
)
vl_gpt = vl_gpt.to(torch.bfloat16).cuda().eval()

conversation = [
    {
        "role": "<|User|>",
        "content": f"<image_placeholder>\n{question}",
        "images": [image],
    }
]
```

公众号 · 雨飞AI笔记

以多模态理解为例，我们需要修改相关代码中的几个部分，大家可以根据我下面放出来的代码片段，将`model_path`、`image`、`question` 变量的内容进行修改，替换为自己模型的路径、图片所在的路径以及想要提问的内容。

```
1 | import torch`from transformers import AutoModelForCausalLM`from janus.models import MultiModalityCausalLM, VL
```

然后在命令行中执行这个代码，出现如下方所示的内容，表示案例执行成功，其中蓝色框里就是 Janus-Pro-1B 输出的内容。

```
(llm) PS E:\models\Janus-main> python .\mtl.py
Python version is above 3.10, patching the collections module.
D:\program\anaconda3\envs\llm\lib\site-packages\transformers\models\auto\image_processing_auto.py:590: FutureWarning: The image_processor_class argument is deprecated and will be removed in v4.42. Please use 'slow_image_processor_class', or 'fast_image_processor_class' instead
warnings.warn(
Using a slow image processor as 'use_fast' is unset and a slow processor was saved with this model. 'use_fast=True' will be the default behavior in v4.48, even if the model was saved with a slow processor. This will result in minor differences in outputs. You'll still be able to use a slow processor with 'use_fast=False'.
You are using the default legacy behaviour of the <class 'transformers.models.llama.tokenization_llama_fast.LlamaTokenizerFast'>. This is expected, and simply means that the 'legacy' (previous) behavior will be used so nothing changes for you. If you want to use the new behaviour, set 'legacy=False'. This should only be set if you understand what it means, and thoroughly read the reason why this was added as explained in https://github.com/huggingface/transformers/pull/24565 - if you loaded a llama tokenizer from a GGUF file you can ignore this message.
Some kwargs in processor config are unused and will not have any effect: add_special_token, mask_prompt, ignore_id, sft_format, image_tag, num_image_tokens.
You are a helpful language and vision assistant. You are able to understand the visual content that the user provides, and assist the user with a variety of tasks using natural language.

<|User|>: <image_placeholder>
Extract all information from this image and convert them into markdown format.

<|Assistant|>: # Visual Encoding

## Decoupling Visual Encoding
- **Image**: A muscular Doge with a confident and powerful appearance.
- **Text**: "Decoupling Visual Encoding"

## Single Visual Encoder
- **Image**: A sad Doge with a small and weak appearance.
- **Text**: "Single Visual Encoder"

The image humorously contrasts the strength of visual encoding methods, with "Decoupling Visual Encoding" being depicted as more powerful and effective.
(llm) PS E:\models\Janus-main>
```

公众号 · 雨飞AI笔记

四、DeepSeek-R1 实战

DeepSeek R1 模型，目前只有后缀带 `qwen`、`llama` 的预训练模型可以在本地使用 `transformers` 进行部署，也就是可以参考我们上面的安装步骤。

以 `qwen` 为后缀名的示例代码可以参考这个网站：

AI大模型-大飞 关注

10 12 0 分享

成功执行后，可以在本地看到 标识符，这个就是思维链的推导过程，由于默认情况下只输出 512 个字符，推理过程偏长时，输出不完整。这个时候，需要在代码中，找到 512，把它调大些，比如 2048、4096 就可以看到完整的输出内容了。

```
(llm) PS E:\models\Janus-main> python .\qwen.py
Setting 'pad_token_id' to 'eos_token_id':151643 for open-end generation.
<think>
Okay, so I need to write a short introduction to a large language model, specifically by Qwen, created by Alibaba Cloud. Hmm, where do I start? I'm not entirely sure what exactly a large language model is, but I know it's something like ChatGPT or others that can understand and generate human-like text.

Alright, Qwen is created by Alibaba Cloud, so I should probably look into their products. I remember hearing about Alibaba Cloud being a big player in cloud computing, offering various services like AI and machine learning. So, Qwen must be their big language model. Maybe it's an AI tool that can handle text generation, translation, or maybe even some conversational capabilities.

I should probably think about the purpose of the introduction. It should explain what a large language model is, mention its key features, and perhaps give some context about Alibaba Cloud and how they developed it. But since I'm just starting out, I need to make sure I cover these points clearly.

Wait, how do I structure this? Maybe start with a general statement about language models and then introduce Qwen, highlighting its significance from Alibaba Cloud's perspective. I should also talk about the benefits or unique aspects of Qwen compared to others, but since I don't have specific details, I'll keep it general.

I should also include some technical terms, like "neural networks," "transformer architecture," and "pre-trained models." But I need to explain what those are in simple terms. Maybe I can define them briefly or link them to the model.

Let me think about the flow. Start with an introduction to language models, then introduce Qwen, mention Alibaba Cloud's role, talk about the model's features, and conclude with its impact or benefits. That should cover it.

Wait, I should make sure the language is clear and not too technical. Since I'm a beginner, I don't want it to sound too complex. I'll use simple sentences and avoid jargon where possible.

Also, I should check if I'm using the correct terms. For example, "large language model" is straightforward, but maybe I should explain terms like "neural networks" if I'm not entirely sure. But since it's for a general introduction, I can keep it simple.

I think I have a good outline now. I'll start with a general statement about language models, introduce Qwen, mention Alibaba Cloud's role, discuss the model's features, and wrap it up with its significance. I'll make sure it's clear and concise.
(llm) PS E:\models\Janus-main> |
```

下面是我把输出长度调整到 2048 之后的结果，可以看到 、 的标识符就都出来了。

```
(llm) PS E:\models\Janus-main> python .\qwen.py
Setting 'pad_token_id' to 'eos_token_id':151643 for open-end generation.
<think>
Okay, I need to create a short introduction to a large language model, specifically from Qwen, created by Alibaba Cloud. Let me start by understanding what a large language model is. It's a type of AI that can understand and generate human language, right? So, it can read text, understand contexts, and produce coherent responses.

Now, Qwen is a product of Alibaba Cloud. I should think about what Alibaba Cloud offers. They probably have various AI platforms, and Qwen is one of them. I should highlight its capabilities and maybe mention its unique features.

I should mention that Qwen is designed for natural language processing tasks, which means it's good at understanding and generating human-like text. It can handle a wide range of tasks like answering questions, summarizing texts, and even translating. Maybe it's also used in various industries for tasks like customer service or content creation.

I should also touch on the benefits of using a large language model, such as being able to generate responses that are contextually appropriate, which can be useful for businesses and individuals who need accurate information quickly.

It's important to make it sound professional but friendly. I should avoid jargon and keep the tone engaging. I'll structure it with a brief introduction, then list some key features, and end with a call to action or a statement about its effectiveness.

Let me think about how to phrase it. Maybe start by introducing the AI as a tool for generating text, then mention its capabilities, and conclude with its potential applications and benefits.

I should also make sure the introduction flows smoothly, connecting each idea logically. Maybe use some transition words to connect the points, like "First, Qwen is a powerful AI designed for generating text." Then, elaborate on its features, and end with its role in various applications.


I should also check if there are any specific use cases or industries where Qwen is particularly effective. For example, maybe it's used in marketing, customer service, or research. Including that could make the introduction more relevant.

Lastly, I'll ensure the language is concise and engaging, avoiding any technical terms that might confuse the reader. The goal is to present Qwen as a versatile and effective tool for text generation, suitable for a wide range of applications.
</think>
Qwen is a cutting-edge AI developed by Alibaba Cloud, designed to excel in generating natural and contextually appropriate text. With its robust natural language processing (NLP) capabilities, Qwen is renowned for its ability to understand and respond to a diverse range of tasks
(llm) PS E:\models\Janus-main> |
```

最后，上面网站的代码只支持以 qwen 为后缀名的模型，大家可以根据自己的显存大小去体验下本地部署。蒸馏出来的模型，效果肯定要比原版的671B的模型差不少，根据我们自己的体验，要想在本地获得还不错的结果，最低选用32b的模型。因此，很多文章说着可以在本地体验R1模型，但也就是简单体验下，32b模型部署至少要32G内存，很多人电脑远达不到这个配置。

CSDN官方认证

AI大模型 全套学习资料 微信扫码领取



CSDN @AI大模型-大飞

如何学习AI大模型？

我在一线互联网企业工作十余年里，指导过不少同行后辈。帮助很多人得到了学习和成长。

我意识到有很多经验和知识值得分享给大家，也可以通过我们的能力和经验解答大家在人工智能学习中的很多困惑，所以在工作繁忙的情况下还是坚持各种整理和分享。但苦于知识传播途径有限，很多互联网行业朋友无法获得正确的资料得到学习提升，故此将并将重要的AI大模型资料包括AI大模型入门学习思维导图、精品AI大模型学习书籍手册、视频教程、实战学习等录播视频免费分享出来。



AI大模型-大飞

关注

👍 10



🌟 12

💬 0

🔗 分享

L1阶段-实践理解大模型				L2阶段-AI大模型应用开发工程实践					
通俗理解	通过真正的深入了解ChatGPT，文心一言，星火大模型，智谱清言等各类大模型工具，真正掌握如何提升工作效率，而不是简单的聊天	项目实践安排及应用举例 (AGI大模型日新月异，它的智商与日俱增，实践安排会根据大模型发展情况不断调整)	1: 远程实践项目 (选项一)： 项目简介：用OpenAI 开源API做网文作者，专门为用户提供高产支持。 大模型将是你的写作伙伴，帮你润色文章进行润色；帮你构思故事章节；帮你拓展整个故事，毫无阻碍大模型将辅助你能够在内容创作上成为一位高产作家。	2: 远程实践项目 (选项一) 项目简介：基于ChatGLM-4等国内大模型API实现运营文案高手。	3: 远程实践项目 (选项一) 项目简介：基于提示工程的代码生成器实践。大模型可以通过代码补充，代码生成，代码优化，生成测试用例等方法帮助程序员提高编程效率和代码质量。大模型最擅长的是编程方面的辅助，给程序员在软件开发的整个工程项目期为工程师们提供支持。	沟通能力	通过程序灵活运用大模型API接口，借助现有的大模型的能力，构建适合我们行业需要的应用程序。	项目实践安排及应用举例 (AGI大模型日新月异，它的智商与日俱增，实践安排会根据大模型发展情况不断调整)	1: 远程实践项目 (选项一)： 项目简介：大型预训练模型来帮助用户更高效地创建、编辑、理解和管理文档的智能工具。文档总结能力是职场白领必备的技能，大模型可以在文档生成、文本编辑、内容总结、信息检索、文档分析、多语言支持等多个领域帮助用户极大地提升个人和企业在此类处理上的效率。
能力收获	真正明白什么是大模型，合理利用大模型的各种AIGC工具来帮助减少重复劳动，提升工作效率。					能力收获	基于GPT现有的模型进行优化，并学会利用GPT创造自己第一个商业级别的App		项目简介：大型预训练模型来帮助用户更高效地创建、编辑、理解和管理文档的智能工具。文档总结能力是职场白领必备的技能，大模型可以在文档生成、文本编辑、内容总结、信息检索、文档分析、多语言支持等多个领域帮助用户极大地提升个人和企业在此类处理上的效率。
适用人群	会操作手机或者电脑的学生与职场人群					适用人群	会操作电脑，想了解如何利用接口API，设计出更切中用户需要的交互体验的产品，希望提升自己的工作效率以及学习效率的人。		2: 远程实践项目 (选项一) 项目简介：大模型在医学任务中表现出色，因为它们能够捕捉到文本中的复杂关系和上下文信息。这些模型通常需要使用大量的标注医疗数据进行训练，以便能够准确地识别各种医学实体。
课程内容	1.1 深入理解大模型 1.2 文心一言，星火，智谱清言，盘古等各类AIGC工具的灵活运用 1.3 大模型成功背后的基本原理 1.4 GPT-3.5-GPT-4类应用 1.5 python编程入门 1.6 提示词工程prompts					课程内容	2.1 Python强化学习 2.2 大模型的优缺点深入理解； 2.3 理解Function Calling提升大模型的准确度； 2.4 RAG&Embedding优化大模型，让专业领域知识得以实现智能化； 2.5 向量数据库精通 2.6 GPTs&Assistant API打造自己的GPT		项目简介：大模型在医学任务中表现出色，因为它们能够捕捉到文本中的复杂关系和上下文信息。这些模型通常需要使用大量的标注医疗数据进行训练，以便能够准确地识别各种医学实体。
能力评估	各种大模型的订阅费用，一般国内的模型免费或者很低费用，国外OpenAI的GPT-3.5/GPT-4大概是10\$/月,按照使用量付费。					能力评估	gpt-4 使用计费方式 input费用：0.03\$/1000tokens output费用：0.06\$/1000tokens 1M Tokens大概是45\$ (预计使用4个月) gpt-3.5约为gpt-4的1/20		医学命名实体识别系统 (Named Entity Recognition, NER) 在医疗信息提取、临床决策支持、药物研发、医疗数据分析等领域有着广泛的应用。通过自动化地识别和提取这些关键信息，可以大大提高医疗数据处理的速度和准确性，为医疗专业人士和研究人士提供有力的支持。
上课形式	线上直播课+远程项目实战+在线答疑					上课形式	线上直播课+远程项目实战+在线答疑		
总课时	12课时左右					总课时	10课时左右		
L3阶段-大模型应用架构进阶实践				L4阶段-打造符合自己需要的私有大模型					
通俗理解	结合大模型以及各种大模型应用框架，让大模型在某个领域具备可以应用的能力	项目实践安排及应用举例 (AGI大模型日新月异，它的智商与日俱增，实践安排会根据大模型发展情况不断调整)	1: 远程实践项目 (选项一)： 项目简介：利用大型预训练模型来处理和理解图片内容，并据此回答用户提出的相关问题。该系统能够识别图片中的物体、场景、活动和文本等信息，然后根据用户的查询生成准确的回答。系统能够帮我们识别物体、场景、理解、情感分析等多个方面为用户提供一个直观的方式来查询和理解图片中的信息，在新闻报道、社交媒体分析、教育、旅游等领域给予用户快速的视觉信息检索。	2: 远程实践项目 (选项一) 项目简介：大模型打造的客服系统可以模拟人类客服的行为，为用户提供自动化的问答服务、解决问题和处理投诉等。	3: 远程实践项目 (选项一) 项目简介：基于Agents打造AI模拟面试官机器人	沟通能力	结合我们在自己垂直领域对行业的理解和积累的私有知识库，对大模型进行微调，并打造自己的私有大模型	项目实践安排及应用举例 (AGI大模型日新月异，它的智商与日俱增，实践安排会根据大模型发展情况不断调整)	1: 远程实践项目 (选项一)： 项目简介：在医疗领域，智能医生私有大模型是指专门为医疗机构或医疗技术公司定制开发的、用于模拟医生诊断和治疗过程的人工智能模型。智能医生大模型通常基于大量的医疗数据训练，包括电子病历、医学文献、临床指南、药物知识库等，以便能够提供专业的医疗建议和决策支持。通常大模型可以辅助诊断，并能结合患者病历中的基因信息和生活方式推荐个性化的治疗方案。另外还可以承担患者的教育工作，向患者提供健康建议和疾病预防知识。
能力收获	对大模型进行初步精通，让大模型在某个领域的任务表现可以应用					能力收获	学会大模型的微调，并结合自己的商业数据打造出一个自己在商业垂直领域的私有模型		2: 远程实践项目 (选项一) 项目简介：大模型在医学任务中表现出色，因为它们能够捕捉到文本中的复杂关系和上下文信息。这些模型通常需要使用大量的标注医疗数据进行训练，以便能够准确地识别各种医学实体。
适用人群	线上直播课+远程项目实战+在线答疑					适用人群	理解特定行业的特定需求，希望通过学习大模型赋能自己的行业，提升自我价值，甚至希望改变自己公司的工作效率的个人或者公司		医学命名实体识别系统
课程内容	3.1 不同语言模型GPTs的特点分析； 3.2 LangChain框架与不同语言模型的交互； 3.3 Semantic Kernel 3.4 智能体Agent搭建应用； 3.5 MetaGPT的技术方案分析； 3.6 多智能体协同合作构建代理生成器实践 3.7 基于图片的智能信息检索实践； 3.8 无人数字人直播机器人客服实践； 3.9 基于Agents打造AI模拟面试官实践；					课程内容	4.1 开源模型的私有化部署； 4.2 模型微调Fine-Tuning； 4.3 微调生成医疗领域智能医生私有模型 4.4 开源的大模型GPTs微调 4.5 多模态技术详解 4.6 多模态技术项目实战代码生成器		项目简介：大模型在医学任务中表现出色，因为它们能够捕捉到文本中的复杂关系和上下文信息。这些模型通常需要使用大量的标注医疗数据进行训练，以便能够准确地识别各种医学实体。
能力评估	服务器租用 (需求: A100 1-10卡) 微软云: A100 80GB 1卡 ¥15/小时 阿里云: A100 40G 2卡 ¥6800/月 API调用2阶版					能力评估	服务器租用 (需求: A100 2-10卡) 微软云: A100 80GB 1卡 ¥15/小时 阿里云: A100 40G 2卡 ¥6800/月 API调用2阶版		项目简介：大模型在医学任务中表现出色，因为它们能够捕捉到文本中的复杂关系和上下文信息。这些模型通常需要使用大量的标注医疗数据进行训练，以便能够准确地识别各种医学实体。
能力收获	对大模型进行初步精通，让大模型在某个领域的任务表现可以应用					能力收获	服务器租用 (需求: A100 2-10卡) 微软云: A100 80GB 1卡 ¥15/小时 阿里云: A100 40G 2卡 ¥6800/月 API调用2阶版		项目简介：大模型在医学任务中表现出色，因为它们能够捕捉到文本中的复杂关系和上下文信息。这些模型通常需要使用大量的标注医疗数据进行训练，以便能够准确地识别各种医学实体。
上课形式	线上直播课+远程项目实战+在线答疑					上课形式	线上直播课+远程项目实战+在线答疑		
总课时	14课时左右					总课时	12课时左右		
L5阶段-深入大模型原理打造进阶的私有大模型				L6阶段-深入大模型原理打造进阶的私有大模型					
通俗理解	训练入门级别的基座大模型，理解大模型的基本原理逻辑，并能够按照大模型的基本标准和原则以及评估逻辑对大模型进行增量训练，最终得到一个人门级别的基座大模型。	项目实践安排及应用举例 (AGI大模型日新月异，它的智商与日俱增，实践安排会根据大模型发展情况不断调整)	1: 远程实践项目 (选项一)： 项目简介：基于Mistral-7B/ChatGLM3-6B 基于开源大模型ChatGLM3-6B基座，投入大量中文数据集和大规模自训练法进行增量训练，是为了提升模型在特定领域的专业能力,通过增量训练，ChatGLM3-6B模型将不仅具备强大的中文处理能力，还能够在法律领域提供专业的服务和决策支持。这种模型可以用于法律咨询、法律教育、法律研究等多个场景，帮助法律专业人士和公众更好地理解和应用法律知识。	2: 远程实践项目 (选项一) 项目简介：其他AI领域的商业化实践项目如：智慧城市、智慧社区、智慧车间、智慧交通、智慧警务等各智能领域的商业应用项目都在其中。	3: 远程实践项目 (选项一) 项目简介：其他AI领域的商业化实践项目如：智慧城市、智慧社区、智慧车间、智慧交通、智慧警务等各智能领域的商业应用项目都在其中。	沟通能力	深入理解大模型的基本算法，研究算法的优化方案，最终能够为大模型的演进贡献自己的力量	项目实践安排及应用举例 (AGI大模型日新月异，它的智商与日俱增，实践安排会根据大模型发展情况不断调整)	1: 远程实践项目 (选项一)： 项目简介：对于国企客户以及许多对数据合规性和模型输出有严格要求的应用场景来说，确保训练数据的安全性是非常重要的。这样的要求在金融、医疗、法律和其他敏感领域尤其突出。独立训练模型可以确保从数据源开始训练的数据在输出上符合中国法律的要求，适用于国企和其他对合规性有严格要求的客户。这样的模型可以用于提供法律咨询、撰写法律文件、分析法律案例等多种应用，同时确保输出的准确性和合规性。
能力收获	深入了解大模型各种算法，以及结合大模型的发展规律，按照指引进行模型增量训练或进行增量训练					能力收获	训练更高级别的大模型基座，设置大模型的全量微调或增量微调，选择和修改预训练模型底层算法，并提升大模型的性能的能力		其他AI领域的商业化实践项目如：智慧城市、智慧社区、智慧车间、智慧交通、智慧警务等各智能领域的商业应用项目都在其中。
适用人群	学习入门级别的大模型技巧，对AI算法有一定的研究，尤其擅长人工智能方面希望有科技公司提供实践项目学习经验，并能够依托实践找到好工作的技术工作者					适用人群	学习高级大模型底层算法，并完成高级大模型训练技巧，以满足不同业务需求构建特定大模型，并希望在AI算法领域有自己的知名度，发表高质量paper的研究人员。		
课程内容	详细信息咨询参考《大模型微调进阶实训工程》的具体课程					课程内容	详细信息咨询参考《基础训练学习营&大模型算法学习营》的具体课程		
能力评估	服务器租用 (需求: A100 8-20卡) 微软云: A100 40G 2卡 ¥6800/月 阿里云: A100 30GB 8卡 ¥64000/月 微软云: A100 80GB 1卡 ¥15/小时 腾讯云/阿里云 租赁显卡价格: A100 30GB 16W/片					能力评估	服务器租用 (需求: A100 8-20卡) 微软云: A100 40G 2卡 ¥6800/月 阿里云: A100 30GB 8卡 ¥64000/月 微软云: A100 80GB 1卡 ¥15/小时 腾讯云/阿里云 租赁显卡价格: A100 30GB 16W/片		
上课形式	线下实习+一对一实习老师指导					上课形式	线下实习+一对一论文导师指导		
总课时	6个月脱产学习					总课时	6个月脱产学习		

第一阶段： 从大模型系统设计与入手，讲解大模型的主要方法；

第二阶段： 在通过大模型提示词工程从Prompts角度入手更好发挥模型的作用；

第三阶段： 大模型平台应用开发借助阿里云PAI平台构建电商领域虚拟试衣系统；

第四阶段： 大模型知识库应用开发以LangChain框架为例，构建基于大模型的智能问答系统；

第五阶段： 大模型微调开发借助以大健康、新零售



AI大模型-大飞

关注

10

12

0

分享

第七阶段：以大模型平台应用与开发为主，通过星火大模型，文心大模型等成熟大模型构建大模型行业应用。



AI大模型-大飞 关注

- 能够利用大模型解决相关实际项目需求：大数据时代，越来越多的企业和机构需要处理海量数据，利用大模型技术可以更好地处理这些数据，提高数据分析和决策的准确性。因此，掌握大模型应用开发技能，可以让程序员更好地应对实际项目需求；

- 基于大模型和企业数据AI应用开发，实现大模型理论、掌握GPU算力、硬件、LangChain开发框架和项目实战技能，学会Fine-tuning垂直训练大模型（数据准备、数据蒸馏、大模型部署）一站式掌握；

- 能够完成时下热门大模型垂直领域模型训练能力，提高程序员的编码能力：大模型应用开发需要掌握机器学习算法、深度学习框架等技术，这些技术的掌握可以提高程序员的编码能力和分析能力，让程序员更加熟练地编写高质量的代码。



AI大模型学习路线汇总

大模型视频合集

001-先导篇【课程永久更新】	2024/4/7
002-具体事项和更新周期	2024/4/7
003-课程内容介绍（能学到哪些内容）	2024/4/7
004-AIGC的前世今生	2024/4/7
005-各个大语言模型有什么区别？又该如何去选择？	2024/4/7
006-【课程正式开始】私有化大模型是什么？	2024/4/7
007-知识库、微调、AlAgent，分别是什么？（简单篇及）	2024/4/7
008-【重要】开源是什么？闭源是什么？两者有何区别？	2024/4/7
009-提示词工程、提示词工程进阶（进阶篇）	2024/4/7
010-提示词工程进阶（进阶篇）	2024/4/7
011-提示词（作业讲解）	2024/4/7
012-【0基础必看】计算机基础知识	2024/4/7
013-【实操前铺垫】云服务器的基本概念	2024/4/7
014-云服务器基础篇（上）	2024/4/7
015-云服务器基础篇（下）	2024/4/7
016-计算机基础篇：linux指令（1）	2024/4/7
017-计算机基础篇：Linux（2）	2024/4/7
018-计算机基础篇：linux（3）	2024/4/7
019-【偏难，看不懂可跳过】机器学习 and 神经网络基础知识	2024/4/7
020-AI以及大模型的进阶核心知识点（重要，请反复观看！）	2024/4/7

大模型落地应用案例119页PPT



大模型实战案例

大模型PDF书籍合集

- 202402月更新-【AI金融新纪元】系列报告（一）：金融垂类大模型试用体验.pdf
- 202402月更新-2023 移动通信与AI融合的数据格式和模型建议书（第一阶段）.pdf
- 202402月更新-2023赛分析企业大模型市场厂商评估报告：滴滴科技.pdf
- 202402月更新-2023产业大模型应用白皮书.pdf
- 202402月更新-2023大模型落地应用案例集.pdf
- 202402月更新-2023金融大模型技术创新与应用探索报告.pdf
- 202402月更新-2023年AIGC场景应用展望研究报告.pdf
- 202402月更新-2023前沿大模型的风险、安全与治理报告.pdf
- 202402月更新-2023数字中国年度报告.pdf
- 202402月更新-2023新一代人工智能基础设施白皮书.pdf
- 202402月更新-2023《生成式AI模型设计》设计评估标准白皮书.pdf
- 202402月更新-2024大语言模型能力测评报告.pdf
- 202402月更新-AI大模型产业正发生哪些变化？.pdf
- 202402月更新-AI时代领先者，大装置+大模型推动AGI落地.pdf
- 202402月更新-ChatGPT模型大更新，省级数据局陆续挂牌.pdf
- 202402月更新-GPT商店下周正式上线，美图开放AI视觉大模型.pdf
- 202402月更新-Meta 2024Q1收入指引超预期，发布开源大模型CodeLlama70B.pdf
- 202402月更新-OpenAI发布重大更新，大模型使用成本将进一步降低.pdf
- 202402月更新-OpenAI宣布将上线「自定义GPT商店」，网易有道发布教育大模型子曰：.pdf
- 202402月更新-Vision Pro预售火爆，国内外大模型持续迭.pdf
- 202402月更新-产业深度：大模型赋能座舱、智能座舱的新挑战.pdf

1-大模型 (LLMs) 基础篇	2024/3/23 19:45	Foxit Phantom P...	482
2-Layer normalization 篇	2024/3/23 19:45	Foxit Phantom P...	489
3-LLMs 激活函数篇	2024/3/23 19:45	Foxit Phantom P...	375
4-Attention 升级篇	2024/3/23 19:45	Foxit Phantom P...	411
5-transformers 操作篇	2024/3/23 19:45	Foxit Phantom P...	228
6-LLMs 损失函数篇	2024/3/23 19:45	Foxit Phantom P...	356
7-相似度量函数篇	2024/3/23 19:45	Foxit Phantom P...	175
8-大模型 (LLMs) 进阶篇	2024/3/23 19:45	Foxit Phantom P...	1,019
9-大模型 (LLMs) 微调篇	2024/3/23 19:45	Foxit Phantom P...	2,958
10-LLMs 训练经验帖	2024/3/23 19:45	Foxit Phantom P...	254
11-大模型 (LLMs) langchain 入门篇	2024/3/23 19:45	Foxit Phantom P...	631
12-多轮对话中让LLM保持长期记忆的技巧...	2024/3/23 19:45	Foxit Phantom P...	362
13-基于langchain RAG问答应用实践	2024/3/23 19:46	Foxit Phantom P...	376
14-基于LLM+向量的文档对话 经验篇	2024/3/23 19:46	Foxit Phantom P...	2,208
15-大模型 RAG 经验篇	2024/3/23 19:46	Foxit Phantom P...	1,443
16-LLM文档对话 —— pdf解析关键问题	2024/3/23 19:46	Foxit Phantom P...	2,191
17-大模型 (LLMs) RAG 版面分析——...	2024/3/23 19:46	Foxit Phantom P...	662
18-大模型 (LLMs) RAG 版面分析——...	2024/3/23 19:46	Foxit Phantom P...	483
19-大模型外挂知识库优化 —— 如何利用...	2024/3/23 19:46	Foxit Phantom P...	734
20-大模型外挂知识库优化 —— 负载样本...	2024/3/23 19:46	Foxit Phantom P...	705
21-RAG (Retrieval-Augmented Generation...	2024/3/23 19:46	Foxit Phantom P...	617
22-检索增强生成(RAG) 优化策略篇	2024/3/23 19:46	Foxit Phantom P...	2,708
23-大模型 (LLMs) RAG —— 关键痛点...	2024/3/23 19:46	Foxit Phantom P...	1,349
24-大模型 (LLMs) RAG 优化策略 ——	2024/3/23 19:47	Foxit Phantom P...	1,086

LLM面试题合集

AI产品经理合集

- 1.AI大模型学习路线图
- 2.100套AI大模型商业化落地方案
- 3.100集大模型视频教程
- 4.200本大模型PDF书籍
- 5.LLM面试题合集
- 6.AI产品经理资源合集

👉 获取方式：

😁 有需要的小伙伴，可以保存图片到wx扫描二v码免费领取【保证100%免费】



AI大模型学习资料领取
微信名片

使用 **Ollama** 的 **solar-pro**：本地生物信息学大模型，最新模型了解胆固醇和遗传学

iCloudEnd 的博客 66

生物信息学似乎对大多数法学硕士来说都具有挑战性，但本地可用的 **Solar-Pro** 却不同！在我给它一些指导后，它也能解决我简单的隐藏多肽文字问题。您可以从 ...

Deepseek发布的**Janus-Pro-1B**初体验

m0_57610007 的博客 1711

deepseek，**Janus-Pro-1B**快速上手

联想Y7000+RTX4060+i7+Ubuntu22.04运行**DeepSeek**开源多模态大模型**Janus-Pro-1B**+本地部署

hzm8341 的博客 1524

在笔记本电脑上手搓**Deepseek**最近开源的多模态大模型。

如何获取 **DeepSeek** 多模态大模型 **Janus-Pro-7B**

Debug yourself! 3152

DeepSeek 团队近期开源了新一代多模态模型 **Janus-Pro-7B**，该模型在图像生成和多模态理解方面表现卓越，超越了OpenAI的DALL-E 3，并在基准测试中取得了...

Janus-Pro 论文解读：**DeepSeek** 如何重塑多模态技术格局

进一步有进一步的欢喜~ 1557

在人工智能的浩瀚星空中，多模态理解与生成模型犹如耀眼的星座，不断推动着技术边界的拓展。**Janus-Pro**作为这一领域的新兴力量，以其卓越的性能和创新的架...

deepseek Janus-Pro-7B 模型 CPU 加载运行

lianmengde 的博客 1842

【代码】**deepseek Janus-Pro-7B 模型 CPU 加载运行**。

DeepSeek又开源**Janus-Pro**，7B多模态强势登顶，OpenAI彻底慌了

2401_85375151 的博客 1102

大家新春快乐，继之后，**DeepSeek**深夜又放大招，开源下一代和。先看效果，后面进行技术报告解读（回复“”可获取），效果上，“Und.”和“Gen.”分别表示“理解”...

DeepSeek 第二弹：**Janus-Pro** 文生图模型

云水木石 2729

最近，**DeepSeek** 可谓是科技圈的焦点，还火出了圈外，掀起了一场全民创作热潮。大家纷纷借助**DeepSeek R1**挥洒才情，实现诗人、小说家的梦想。然而，就在...

本地部署**DeepSeek** 多模态大模型**Janus-Pro-7B**

weixin_44626085 的博客 3594

在众多AI模型中，**Janus-Pro-7B**犹如一颗耀眼的星星。它代表了理解与生成一体化的新纪元。想象一下，它不仅能够理解文本，还能生成高质量图像，甚至可以回...

Deepseek多模态大模型**Janus-Pro-7B**在医疗领域的简单应用可行性测试

m0_63171455 的博客 1124

综上所述**Janus Pro**完成了 5 种常见医学影像图的多模态理

deepseek Janus-Pro-7B加载运行



AI大模型-大飞

关注

👍 10



🌟 12

💬 0

🔗 分享

### 如何加载和运行Janus-Pro-7B模型 为了加载并运行Janus-Pro-7B模型，可以利用`transformers`库中的工具来简化这一过程。以下是具体实现方法：#### 使用...	
deepseek Janus-Pro ### DeepSeek Janus-Pro 文档与特性#### 模型扩展性及其影响 DeepSeek 的 Janus-Pro 模型从 1.5B 参数量扩展到了 7B 参数量，在处理多模态理解和视觉生成...	02-02
Janus-Pro-1B 本地部署 ### Janus-Pro-1B 模型本地部署教程#### 准备工作 为了成功在本地环境中部署Janus-Pro-1B模型，需先安装必要的依赖库并准备相应环境。这通常涉及Pytho...	01-31
janus-pro-7b 部署 ### 如何部署 Janus-Pro-7B 模型 为了成功部署Janus-Pro-7B模型，需遵循特定流程来准备环境并加载模型。首先，确认已安装Python以及pip工具，这是运行任何...	02-01
信息安全专业2025最新毕业设计选题汇总：课题精选 最新发布 信息安全专业2025最新毕业设计选题合集涵盖了深度学习、机器学习、算法、人工智能、大数据、信息安全、推荐系统、目标检测等多个热门领域。对于计算机专...	Hai_Lang_IT的博客 694
Assembly语言的移动应用开发 Assembly语言是与计算机硬件紧密结合的一种低级编程语言。它为计算机的指令集架构提供了人类可读的语法格式，允许开发者直接与机器代码进行交互。每种计...	2501_90373113的博客 267
关于大模型 AGI 应知应会__生在AI发展的时代 大模型（Large Language Models, LLMs）是指具有大规模参数和复杂计算结构的深度学习模型，通常由深度神经网络构建而成，拥有数十亿甚至数千亿个参数。...	leichaohahah的博客 595
具有HiLo注意力的快速视觉Transformer 视觉Transformer（ViTs）在计算机视觉领域引发了最新且最重要的突破。其高效设计大多以计算复杂度的间接指标，即浮点运算数（FLOPs）为指导，然而，该指...	AI浩 582
Adaptive LLM Transformer ² TRANSFORMER-SQUARED: SELF-ADAPTIVE LLMS 挺有意思的，是一家日本AI公司SakanaAI的论文（我以前写过他们的不训练提升模型的能力的文章，感兴...	周博洋的博客 346



AI大模型-大飞

关注

10



12

0



分享